Recepti i recenzije

Predmet: Sistemi baza podataka Profesor: Vladimir Dimitrieski Asistent: Jelena Hrnjak

Studenti: Sonja Mihajlović IN33/2020 Luka Petrović IN26/2020

Opis skupova podataka

Skupovi podataka sadrže:

- → Informacije o svakom receptu uključuju vreme kuvanja, broj porcija, sastojke, nutritivne vrednosti, uputstva i druge detalje.
- → informacije o svakoj recenziji uključuju autora, ocenu, tekst recenzije i još mnogo toga.

Broj zapisa: 522,517 recepata iz 312 različitih kategorija 1,401,982 recenzija od 271,907 različitih korisnika

Datoteke: recipes.csv & reviews.csv

Link: https://www.kaggle.com/datasets/irkaal/foodcom-recipes-and-reviews?select=reviews.csv

Semantika kolona:

Skup podataka o receptima sadrži 28 kolona.

Recipeld: ID recepta

• Name: Ime

AuthorId: ID autora

AuthorName: Ime autoraCookTime: Vreme kuvanja

PrepTime: Vreme pripreme

• **TotalTime:** Ukupno vreme

DatePublished: Datum objavljivanja

• **Description:** Opis

• **Images:** Slike

RecipeCategory: Kategorija recepta

• **Keywords:** Ključne reči

RecipeIngredientQuantities: Količine sastojaka recepta

• RecipeIngredientParts: Delovi sastojaka recepta

AggregatedRating: Prosečna ocena

ReviewCount: Broj recenzija

• **Calories:** Kalorije

• **FatContent:** Sadržaj masti

• **SaturatedFatContent:** Sadržaj zasićenih masti

• **CholesterolContent:** Sadržaj holesterola

• **SodiumContent:** Sadržaj natrijuma

CarbohydrateContent: Sadržaj ugljenih hidrata

• **FiberContent:** Sadržaj vlakana

• **SugarContent:** Sadržaj šećera

ProteinContent: Sadržaj proteina

RecipeServings: Broj porcija
 RecipeSite Prince recepta

RecipeYield: Prinos recepta

RecipeInstructions: Uputstva za recept

Semantika kolona:

Skup podataka o recenzijama sadrži 8 kolona.

- **ReviewId:** ID recenzije
- Recipeld: ID recepta
- Authorld: ID autora
- AuthorName: Ime autora
- Rating: Ocena
- **ReviewText:** Tekst recenzije
- DateSubmitted: Datum podnošenja
- **DateModified:** Datum izmene

Predlog logičke šeme baze podataka - Kolekcija: Recipes

- Recipeld: Int
- Name: String
- Author:
 - AuthorId: Int
 - AuthorName: String
- Times:
 - CookTime: String
 - PrepTime: String
 - TotalTime: String
- DatePublished: DateTime
- Description: String
- Images: [String]
- RecipeCategory: String
- Keywords: [String]
- Ingredients:
 - Quantity: String
 - Part: String

- AggregatedRating: Float
- ReviewCount: Float
- Nutrition
 - Calories: Float
 - FatContent: Float
 - SaturatedFatContent: Float
 - CholesterolContent: Float
 - SodiumContent: Float
 - CarbohydrateContent: Float
 - FiberContent: Float
 - SugarContent: Float
 - ProteinContent: Float
- RecipeServings: Float
- RecipeYield: String
- Recipelnstructions: [String]

Predlog logičke šeme baze podataka - Kolekcija: Reviews

- Reviewld: Int
- Recipeld: Int
- Authorld: Int
- AuthorName: String
- Rating: Float
- ReviewText: String
- DateSubmitted: DateTime
- DateModified: DateTime

Predlog logičke šeme baze podataka - Kolekcija: Recipes

```
"RecipeId": { "0": 38 },
 "Name": { "0": "Low-Fat Berry Blue Frozen Dessert" }.
"CookTime": { "0": "P724H" },
"PrepTime": { "0": "P725H" },
"TotalTime": { "0": "P745H" },
"DatePublished": { "0": "1999-08-09721:46:002" },
 "Description": { "0": "Make and share this Low-Fat Berry Blue Frozen Dessert recipe from Food.com." }.
     "https://img.sndimg.com/food/image/upload/w 555,h 416,c fit,fl progressive,q 95/v1/img/recipes/38/YUeirxMLQaeE1h3v3qnM 229%20berry%20blue%20frzn%20dess.jpg",
      "https://img.sndimg.com/food/image/upload/w 555.h 416.c fit.fl progressive.a 95/v1/img/recipes/38/AFPDDHATN2O0b1CDpDAT 255%20berry%20blue%20frzn%20dess.jpg",
      https://img.sndimg.com/food/image/upload/w_555,h_416,c_fit.fl_progressive.g_95/v1/img/recipes/38/UYgf9nwMT2SGGJCuzILO_228%20berry%20blue%20frzn%20dess.jpg",
      https://img.sndimg.com/food/image/upload/w 555,h 416,c fit,fl progressive,q 95/v1/img/recipes/38/PeBMJN2TGSaYks2759BA 20140722 202142.jpg",
      "https://img.sndimg.com/food/image/upload/w 555,h 416,c fit,fl progressive,g 95/v1/img/recipes/38/picuaETeN.jpg",
      https://img.sndimg.com/food/image/upload/w 555,h 416,c fit,fl progressive,a 95/v1/img/recipes/38/pictzvxW5.jpg"
   "0": ["Dessert", "Low Protein", "Low Cholesterol", "Healthy", "Free Of...", "Summer", "Weeknight", "Freezer", "Easy"]
  "RecipeIngredientParts": {
  "0": ["blueberries", "granulated sugar", "vanilla yogurt", "lemon juice"]
},
"AggregatedRating": { "0": 4.5 },
"ReviewCount": { "0": 4.0 },
"70": 170 9 }
 "Calories": { "0": 170.9 },
"FatContent": { "0": 2.5 },
 "SaturatedFatContent": { "0": 1.3 },
"CholesterolContent": { "0": 8.0 },
"SodiumContent": { "0": 29.8 },
 "CarbohydrateContent": { "0": 37.1 },
 "SugarContent": { "0": 30.2 },
 "ProteinContent": { "0": 3.2 },
"RecipeServings": { "0": 4.0 },
 "RecipeYield": { "0": null },
 "RecipeInstructions": {
     "Toss 2 cups berries with sugar.",
     "Let stand for 45 minutes, stirring occasionally.".
      "Transfer berry-sugar mixture to food processor.".
     "Add yogurt and process until smooth.",
     "Strain through fine sieve. Pour into baking pan (or transfer to ice cream maker and process according to manufacturers' directions).\",
     "Freeze uncovered until edges are solid but centre is soft. Transfer to processor and blend until smooth again.",
     "Return to pan and freeze until edges are solid.",
     "Transfer to processor and blend until smooth again.",
     "Fold in remaining 2 cups of blueberries.",
      "Pour into plastic mold and freeze overnight. Let soften slightly to serve."
```

Predlog logičke šeme baze podataka - Kolekcija: Reviews

```
{
    "ReviewId": { "0": 2 },
    "RecipeId": { "0": 992 },
    "AuthorId": { "0": 2008 },
    "AuthorName": { "0": "gayg msft" },
    "Rating": { "0": 5 },
    "Review": { "0": "better than any you can get at a restaurant!" },
    "DateSubmitted": { "0": "2000-01-25T21:44:00Z" },
    "DateModified": { "0": "2000-01-25T21:44:00Z" }
}
```

Predlog agregacije nad podacima - IN 33/2020

- 1. Izračunati prag kalorija kao polovinu prosečne kalorijske vrednosti svih recepata, zatim odrediti procente niskokaloričnih i visokokaloričnih recepata, i identifikovati autore sa najvećim brojem recepata u obe kategorije
- 2. Identifikovati recepte koji imaju najmanji broj sastojaka i prikaži nazive tih recepata, sastojake, način i vreme pripreme ukoliko se mogu servirati za 4 osobe.
- Prikazati 10 recepata koji spadaju u kategoriju sa ključnom rečju "Chicken" i imaju ocenu veću ili jednaku sa 4. Prikazati recepte ukoliko je vreme pripreme manje od 60min.
- 4. Grupisati recepate po ukupnom vremenu (kratki, srednje kratki, srednje dugi, dugi), potom prikazati procente svih recepata u svakoj od kategorija. Rezultate prikazati u satima.
- 5. Pronaći recepte iz kategorije "Dessert", sortirati po broju recenzija. Zatim izlistati ime tri recepta , prikazati broj recenzija po receptu i tekstualne opise samih recenzija.

Predlog agregacije nad podacima - IN 26/2020

- 1. Prikazati imena 10 autora sa najvećim brojem recepata koji imaju prosečnu ocenu 4.5 ili veću i nalaze se u kategoriji "Steak".
- 2. Prikazati ime, vreme pripreme i sastojke za 10 recepata sa najvećom prosečnom ocenom koji pripadaju kategoriji "Desert", imaju manje od 500 kalorija i mogu biti servirani za 6 osoba i imaju bar 1 review sa 100 karaktera.
- 3. Prikazati naziv recepta, kolicinu kalorija i datum objavljivanja za sve recepte koji spadaju u nezdrave recepte i 'Sydney Mike' je ostavljao recenzije za njih.
- 4. Prikazati ime recepta, broj kalorija, količinu masnoće i proteina i odnos masnoća i proteina recepata koji imaju prosečnu ocenu veću od 4.0, sadrže barem pet sastojaka i ukupno vreme pripreme je između dva i četri sata.
- 5. Prikazati ime recepta, ime autora i datum objavljivanja recepata koji su objavljeni od 2000. godine i sadrže određene sastojke. Prikazani recepti moraju imati najmanje 10 recenzija,a rezultate treba sortirati po prosečnoj oceni u opadajućem redosledu.

REALIZACIJA PROJEKTA

Logička šema za optimizaciju upita - Kolekcije: Recipes i Reviews

- Recipeld: Int
- Name: String
- Author:
 - Authorld: Int
 - AuthorName: String
- Times:
 - CookTime: String
 - PrepTime: String
 - TotalTime: String
- DatePublished: DateTime
- Description: String
- Images: [String]
- RecipeCategory: String
- Keywords: [String]
- Ingredients:
 - Quantity: String
 - Part: String
- AggregatedRating: Float
- ReviewCount: Float

- Nutrition
 - Calories: Float
 - FatContent: Float
 - SaturatedFatContent: Float
 - CholesterolContent: Float
 - SodiumContent: Float
 - CarbohydrateContent: Float
 - FiberContent: Float
 - SugarContent: Float
 - ProteinContent: Float
- RecipeServings: Float
- RecipeInstructions: [String]
- Reviews
 - ReviewId: Int
 - Recipeld: Int
 - AuthorId: Int
 - AuthorName: String
 - o Rating: Float
 - ReviewText: String
 - DateSubmitted: DateTime
 - DateModified: DateTime

Logička šema za optimizaciju upita 2 - Kolekcije: Recipes i Reviews

- Recipeld: Int
- Name: String
- Author:
 - o Authorld: Int
 - AuthorName: String
- Times:
 - CookTime: String
 - PrepTime: String
 - TotalTime: String
- DatePublished: DateTime
- Description: String
- Images: [String]
- RecipeCategory: String
- Keywords: [String]
- Ingredients:
 - Quantity: String
 - Part: String
- AggregatedRating: Float
- ReviewCount: Float

- Nutrition
 - Calories: Float
 - FatContent: Float
 - SaturatedFatContent: Float
 - o CholesterolContent: Float
 - SodiumContent: Float
 - CarbohydrateContent: Float
 - FiberContent: Float
 - SugarContent: Float
 - ProteinContent: Float
- RecipeServings: Float
- RecipeInstructions: [String]
- Reviews
 - ReviewId: Int
 - o Recipeld: Int
 - AuthorId: Int
 - AuthorName: String
 - o Rating: Float
 - ReviewText: String
 - DateSubmitted: DateTime
 - DateModified: DateTime
- ProteinToFatRatio: Float
- IsHealthy: Boolean

Uređivanje podataka

```
def convert_to_minutes(time_str):
   hours = 0
   minutes = 0
   match = re.match(r'PT(?:(\d+)H)?(?:(\d+)M)?', time_str)
   if match:
      if match.group(1):
        hours = int(match.group(1))
      if match.group(2):
        minutes = int(match.group(2))
   total_minutes = hours * 60 + minutes
   return total_minutes
```

```
# Function to process and write a bucket of recipes to the output file
def process and write bucket(bucket, output file):
    restructured recipes = []
    for recipe in bucket:
        restructured recipe = process recipe(recipe)
        restructured recipes.append(restructured recipe)
    with open(output file, 'a', encoding='utf-8') as file:
        for recipe in restructured recipes:
            json.dump(recipe, file)
            file.write('\n')
# Function to read data in buckets from the input file
def read in buckets(file path, bucket size):
    with open(file path, 'r', encoding='utf-8') as file:
        bucket = []
        for line in file:
            recipe = json.loads(line)
            bucket.append(recipe)
            if len(bucket) >= bucket size:
                yield bucket
                bucket = []
        if bucket:
            yield bucket
```

Uređivanje podataka

```
reviews_dict = {}
for _, row in reviews_df.iterrows():
    review = row.to_dict()
    recipe_id = review.pop('RecipeId')
    if recipe_id not in reviews_dict:
        reviews_dict[recipe_id] = []
    reviews_dict[recipe_id].append(review)
```

```
def process recipes(input file, output file):
   with open(input file, 'r', encoding='utf-8') as file:
        recipes = [json.loads(line) for line in file]
   protein to fat ratios = set()
   healthy count = 0
   unhealthy count = 0
   for i, recipe in enumerate(recipes):
        recipes[i], protein to fat ratio, is healthy = compute fields(recipe)
       protein to fat ratios.add(protein to fat ratio)
       if is healthy:
           healthy count += 1
           unhealthy count += 1
   # Save the modified recipes to a new JSON file
   with open(output file, 'w', encoding='utf-8') as file:
        for recipe in recipes:
           json.dump(recipe, file)
           file.write('\n')
```

1. Izračunati prag kalorija kao polovinu prosečne kalorijske vrednosti svih recepata, zatim odrediti procente niskokaloričnih i visokokaloričnih recepata, i identifikovati autore sa najvećim brojem recepata u obe kategorije

```
var lowCalorieThresholdResult = db.merged recipes.aggregate([
 { $group: { _id: null, avgCalories: { $avg: "$Nutrition.Calories" } } },
 { $project: { id: 0, lowCalorieThreshold: { $multiply: ["$avgCalories", 0.5] } } ]).next();
var lowCalorieThreshold = lowCalorieThresholdResult.lowCalorieThreshold;
var pipeline = [
  {\facet: {lowCalorieCount: [
       { $match: { "Nutrition.Calories": { $lte: lowCalorieThreshold } } },{ $count: "count" }],
     highCalorieCount: [
       { $match: { "Nutrition.Calories": { $gt: lowCalorieThreshold } } },{ $count: "count" }],
      totalRecipesCount: [{ $group: { id: null, count: { $sum: 1 } } }],
      lowCalorieAuthor: [
        { $match: { "Nutrition.Calories": { $lte: lowCalorieThreshold } } },
       { $group: { id: "$Author.AuthorName", count: { $sum: 1 } } }, { $sort: { count: -1 } }, { $limit: 1 }],
     highCalorieAuthor: [
        { $match: { "Nutrition.Calories": { $gt: lowCalorieThreshold } } },
        { $group: { id: "$Author.AuthorName", count: { $sum: 1 } } }, { $sort: { count: -1 } }, { $limit: 1 } ]}},
  {$project: {lowCaloriePercentage: { $multiply: [
         { $divide: [{ $arrayElemAt: ["$lowCalorieCount.count", 0] }, { $arrayElemAt: ["$totalRecipesCount.count", 0] }] }, 100]},
      highCaloriePercentage: { $multiply: [
          { $divide: [{ $arrayElemAt: ["$highCalorieCount.count", 0] }, { $arrayElemAt: ["$totalRecipesCount.count", 0] }] },100 ]},
      lowCalorieAuthor: {
        authorName: { $arrayElemAt: ["$lowCalorieAuthor. id", 0] },
       recipeCount: { $arrayElemAt: ["$lowCalorieAuthor.count", 0] } },
      highCalorieAuthor: {
        authorName: { $arrayElemAt: ["$highCalorieAuthor. id", 0] },
       recipeCount: { $arrayElemAt: ["$highCalorieAuthor.count", 0] } }}}];
var results = db.merged recipes.aggregate(pipeline).next();
printJson(results);
```

2. Identifikovati recepte koji imaju najmanji broj sastojaka ako spadaju u kategoriju "Vegetable" i prikaži nazive tih recepata, sastojake, način i vreme pripreme ukoliko se mogu servirati za 4 osobe.

3. Prikazati 10 recepata koji spadaju u kategoriju sa ključnom rečju "Chicken" i imaju ocenu veću ili jednaku sa 4. Prikazati recepte ukoliko je vreme pripreme manje od 60min.

4. Grupisati recepate po ukupnom vremenu (kratki, srednje kratki, srednje dugi, dugi), potom prikazati procente svih recepata u svakoj od kategorija. Rezultate prikazati u satima.

5. Pronaći recepte iz kategorije "Dessert", sortirati po broju recenzija. Zatim izlistati ime tri recepta , prikazati broj recenzija po receptu i tekstualne opise

samih recenzija.

```
db.merged_recipes_rev.aggregate([
    { $match: { RecipeCategory: "Dessert" } },
    { $sort: { ReviewCount: -1 } },
    { $limit: 3 },
    { $project: {
        _id: 0,
        RecipeId: "$RecipeId",
        RecipeName: "$Name",
        TotalReviews: "$ReviewCount",
        Reviews: "$ReviewS"
    }
}
```

1. Prikazati imena 10 autora sa najvećim brojem recepata koji imaju prosečnu ocenu 4.5 ili veću i nalaze se u kategoriji "Steak".

```
db.final.aggregate([
    { $match: { "RecipeCategory": "Steak", "AggregatedRating": { $gte: 4.5 } } },
    { $group: { _id: "$Author.AuthorName", recipeCount: { $sum: 1 } } },
    { $sort: { recipeCount: -1 } },
    { $limit: 10 },
    { $project: { _id: 0, AuthorName: "$_id", recipeCount: 1 } }
])
```

2. Prikazati ime, vreme pripreme i sastojke za 10 recepata sa najvećom prosečnom ocenom koji pripadaju kategoriji "Desert", imaju manje od 500 kalorija i mogu biti servirani za 6 osoba i imaju bar 1 review sa 100 karaktera.

```
db.final.aggregate([
   $match: {
     "RecipeCategory": "Dessert",
     "Nutrition.Calories": { $1t: 500 },
      "RecipeServings": 6,
      "Reviews": { $elemMatch: { "Review": { $regex: /^.{100,}$/ } } }
 },
{
   $sort: {
      "AggregatedRating": -1
 },
   $project: {
     id: 0,
      Name: 1.
      "Times.TotalTime": 1,
      "RecipeIngredient.RecipeIngredientParts": 1,
      "AggregatedRating": 1
```

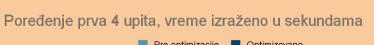
3. Prikazati naziv recepta, kolicinu kalorija i datum objavljivanja za sve recepte koji spadaju u nezdrave recepte i 'Sydney Mike' je ostavljao recenzije za njih.

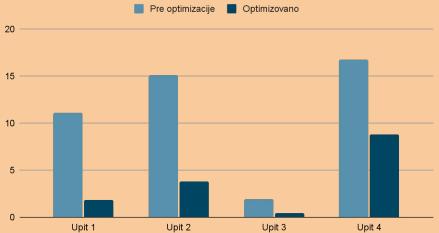
```
db.final.aggregate([
    $match: {
      "IsHealthy": false,
      "Reviews.AuthorName": "Sydney Mike"
    $project: {
      id: 0,
      Name: 1,
      "Nutrition.Calories": 1,
      DatePublished: 1
```

4. Prikazati ime recepta, broj kalorija, količinu masnoće i proteina i odnos masnoća i proteina recepata koji imaju prosečnu ocenu veću od 4.0, sadrže barem pet sastojaka i ukupno vreme pripreme je između dva i četri sata.

5. Prikazati ime recepta, ime autora i datum objavljivanja recepata koji su objavljeni od 2000. godine i sadrže određene sastojke. Prikazani recepti moraju imati najmanje 10 recenzija,a rezultate treba sortirati po prosečnoj oceni u opadajućem redosledu.

REZULTATI OPTIMIZACIJE





Poređenje 5. upita



Indeksi korišćeni u upitima

```
db.merged_recipes.createIndex({ "Nutrition.Calories": 1, "Author.AuthorName": 1 });
db.merged_recipes.createIndex({ "Keywords": "text" })
db.merged_recipes.createIndex({ "Times.TotalTime": 1 })
```

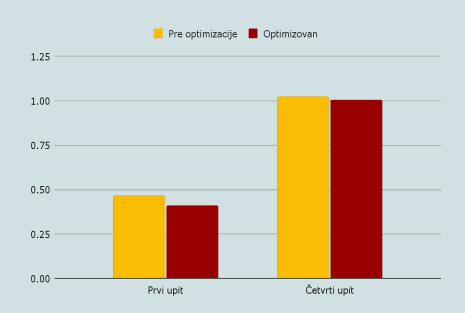
Najbolji indeksi za optimizaciju upita nad kolekcijom merged_recipes su:

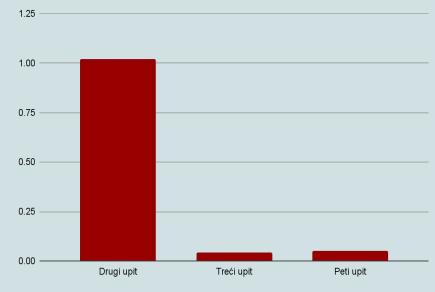
Single Field Indexes - Times.TotalTime

Single Field Indexes, Text index - Keywords

Compound Index koji kombinuje polja Nutrition.Calories i Author.AuthorName

*Vreme je izraženo u sekundama





Korišćeni indexi:

- 1.Compound Index
- 2.Compound Index
- 3. Single Field Index

```
db.final.createIndex({
    "DatePublished": 1,
    "RecipeIngredient.RecipeIngredientParts": 1,
})

db.final.createIndex({
    "RecipeCategory": 1,
    "Reviews.Review": "text"
})

db.final.createIndex({
    "Reviews.AuthorName": 1
})
```

